

Politechnika Wrocławska
Wydział Informatyki i Telekomunikacji

PRACA KOŃCOWA

Wymagania, kryteria oceny i katalog 40 tematów projektów

Studia podyplomowe
„Data Science - Analiza danych od podstaw”

Kierownik studiów: dr inż. Natalia Piórkowska
Dokument uzupełniający do Załączników 5 i 6 programu kształcenia

Spis treści

CZĘŚĆ I

Wymagania dotyczące pracy końcowej

1. Cel i charakter pracy końcowej

Praca końcowa jest samodzielnym projektem analitycznym, w którym uczestnik studiów rozwiązuje jasno zdefiniowany problem na rzeczywistym zbiorze danych, wykorzystując narzędzia i metody poznane w trakcie dwóch semestrów. Zgodnie z Załącznikiem 5 programu kształcenia na jej wykonanie przewidziano 16 godzin pracy własnej.

Celem pracy nie jest uzyskanie jak najwyższej wartości metryki. Celem jest wykazanie, że uczestnik potrafi przeprowadzić kompletny, poprawny metodologicznie i reprodukowalny proces analityczny - od sformułowania pytania, przez przygotowanie danych i budowę modelu, aż do krytycznej oceny wyników i wskazania ograniczeń. Praca, w której model osiąga umiarkowaną jakość, ale proces jest poprawny, a wnioski uczciwe, będzie oceniona wyżej niż praca z wysoką metryką uzyskaną w wyniku błędu metodologicznego.

Zasada nadrzędna: wynik negatywny jest wynikiem. Stwierdzenie „model nie przewyższył prostego punktu odniesienia, a oto dlaczego” jest w tej pracy pełnoprawnym rezultatem, o ile zostało rzetelnie udokumentowane.

2. Zasady ogólne

- Praca końcowa jest wykonywana wyłącznie indywidualnie. Nie dopuszcza się prac zespołowych. Praca zespołowa realizowana jest odrębnie, w ramach kursu „Wspólna realizacja projektu”.
- Każdy uczestnik wybiera jeden temat z katalogu stanowiącego Część II niniejszego dokumentu. Temat może wybrać tylko jedna osoba - obowiązuje kolejność zgłoszeń.
- Katalog obejmuje 40 tematów na 30 uczestników. Nadwyżka jest celowa: zapewnia realny wybór także osobom zgłaszającym się na końcu.
- Dopuszczalne jest zaproponowanie tematu własnego - w szczególności opartego na danych z miejsca pracy uczestnika - po uzyskaniu pisemnej zgody kierownika studiów. Warunkiem jest spełnienie wszystkich wymagań opisanych w niniejszym dokumencie, w tym możliwości weryfikacji analizy przez prowadzącego.
- Temat własny wymaga jednoznacznego uregulowania kwestii praw do danych. Dane objęte tajemnicą przedsiębiorstwa mogą być użyte wyłącznie za pisemną zgodą ich właściciela; w takim przypadku repozytorium nie może być publiczne.
- Praca musi opierać się na danych publicznie dostępnych albo na zbiorach udostępnianych przez kierownika studiów (Załącznik A).

3. Struktura i objętość pracy

Praca powinna mieć następującą strukturę. Podana objętość jest orientacyjna i dotyczy tekstu zasadniczego, bez załączników.

Lp.	Element pracy	Objętość	Co musi zawierać
1	Strona tytułowa	1 s.	Temat, imię i nazwisko, nazwa studiów, rok, nazwisko opiekuna.
2	Streszczenie	150-250 słów	Problem, dane, zastosowana metoda, główny wynik liczbowy, jeden wniosek.
3	Wstęp	2-3 s.	Kontekst zagadnienia, uzasadnienie wyboru tematu, jasno postawiony cel i pytania badawcze (od 1 do 3), krótki przegląd literatury lub istniejących rozwiązań.

Lp.	Element pracy	Objętość	Co musi zawierać
4	Charakterystyka zbioru danych	3-5 s.	Źródło z pełnym odnośnikiem, licencja, sposób pozyskania, liczba obserwacji i zmiennych, tabela zmiennych z typami, statystyki opisowe, analiza braków i wartości odstających, znane ograniczenia zbioru.
5	Metodyka	4-6 s.	Schemat całego procesu (obowiązkowy diagram), sposób przygotowania danych, uzasadnienie wyboru każdej metody, strategia podziału danych i walidacji, wybrane metryki wraz z uzasadnieniem wyboru, ustawienia zapewniające powtarzalność.
6	Wyniki	5-8 s.	Wyniki punktu odniesienia i modeli, tabela porównawcza, co najmniej trzy wykresy o rzeczywistej wartości informacyjnej, analiza istotności cech, analiza błędów modelu.
7	Dyskusja i ograniczenia	2-4 s.	Interpretacja wyników w kategoriach dziedziny, odniesienie do literatury, jawna lista ograniczeń pracy, wskazanie, czego na podstawie tych danych stwierdzić nie można.
8	Wnioski	1-2 s.	Odpowiedzi na postawione we wstępie pytania badawcze oraz kierunki dalszych prac.
9	Bibliografia	-	Minimum 8 pozycji w jednolitym stylu; obowiązkowo cytowanie źródła zbioru danych i publikacji go opisującej, jeśli istnieje.
10	Załączniki	-	Odnośnik do repozytorium z kodem, ewentualne obszerne tabele i dodatkowe wykresy.

Łączna objętość: 20-30 stron dla tematów o poziomie podstawowym i średnim, do 35 stron dla poziomu zaawansowanego. Formatowanie: czcionka 11 pkt, interlinia 1,15, marginesy 2,5 cm, numeracja stron, wszystkie tabele i rysunki numerowane i opisane.

4. Wymagania merytoryczne według poziomu tematu

Każdy temat w katalogu ma przypisany poziom zaawansowania. Poziom nie wpływa na maksymalną ocenę - wpływa na to, czego się od pracy oczekuje. Wymagania są kumulatywne: poziom średni obejmuje wszystko z poziomu podstawowego, poziom zaawansowany - wszystko z obu poprzednich.

Poziom	Wymagania minimalne
Podstawowy (15 tematów)	Kompletna eksploracyjna analiza danych z wnioskami, nie samymi wykresami. Udokumentowane czyszczenie i przygotowanie danych. Prosty punkt odniesienia (model naiwny lub reguła większościowa) oraz co najmniej dwa modele właściwe. Poprawny podział na zbiór treningowy i testowy wykonany przed jakimkolwiek przetwarzaniem. Walidacja krzyżowa. Co najmniej trzy metryki z uzasadnieniem, dlaczego są właściwe dla tego zadania. Interpretacja wyników w języku dziedziny.
Średni (17 tematów)	Dodatkowo: całość przetwarzania zamknięta w obiekcie Pipeline (imputacja, skalowanie i kodowanie wyłącznie wewnątrz pipeline'u). Świadome przeszukiwanie hiperparametrów z zagnieżdżoną lub rozdzielną walidacją. Analiza istotności cech metodą odporną na współliniowość. Systematyczna analiza błędów: gdzie i dla jakich obserwacji model zawodzi. Uzasadniony wybór progu decyzyjnego lub metryki odzwierciedlającej koszt błędu.
Zaawansowany (8 tematów)	Dodatkowo: jeden z następujących elementów, właściwy dla tematu - ocena kalibracji lub interpretowalność metodą SHAP, analiza stabilności lub wrażliwości wyników na wybory analityczne, poprawnie przeprowadzony eksperyment generalizacji (na nowe podmioty, nowy okres, nieznaną klasę),

Poziom	Wymagania minimalne
	albo model głęboki porównany z rzetelnym punktem odniesienia. Wymagana jest jawna dyskusja kosztu obliczeniowego i praktycznej wdrażalności rozwiązania.

5. Wymagania dotyczące kodu i repozytorium

Kod jest równoprawną częścią pracy i podlega ocenie. Praca bez działającego, uporządkowanego kodu nie może zostać dopuszczona do obrony.

5.1. Repozytorium

- Kod przekazywany jest w repozytorium Git (GitHub lub GitLab). Repozytorium może być publiczne albo prywatne z dostępem nadanym opiekunowi - decyduje charakter danych.
- Historia commitów musi odzwierciedlać przebieg pracy. Pojedynczy commit „praca końcowa” zawierający wszystko naraz jest traktowany jako brak spełnienia wymagania.
- Repozytorium nie może zawierać danych osobowych, danych na poziomie indywidualnego pacjenta ani danych objętych tajemnicą przedsiębiorstwa - także w plikach wynikowych i w komórkach notebooków. Ten wymóg dotyczy również historii commitów.

5.2. Wymagana struktura

Struktura repozytorium powinna odpowiadać szablónowi z Załącznika B:

- README.md - opis projektu, źródło danych i jego licencja, instrukcja odtworzenia wyników krok po kroku, spis głównych rezultatów.
- requirements.txt lub environment.yml - wszystkie zależności z przypiętymi numerami wersji.
- data/ - katalog na dane, z plikiem .gitignore. Danych nie commituje się. Zamiast tego dostarcza się skrypt lub instrukcję ich pozyskania.
- notebooks/ - notebooki numerowane w kolejności wykonania (00_pozyskanie_danych, 01_eda, 02_przygotowanie, 03_modele, 04_wyniki).
- src/ - funkcje wielokrotnie używane, przeniesione z notebooków do modułów.
- outputs/ - wykresy, tabele i zapisane modele generowane przez kod.

5.3. Reprodukowalność i jakość

- Ustawione ziarno generatora liczb losowych we wszystkich miejscach, w których występuje losowość (podział danych, inicjalizacja modeli, resampling).
- Uruchomienie notebooków w podanej kolejności na czystym środowisku musi odtworzyć wszystkie liczby i wykresy przedstawione w pracy. Każda liczba w tekście pracy musi dać się wskazać w wyniku działania kodu.
- Notebooki oddawane z komórkami wykonanymi w kolejności rosnącej, bez błędów w wynikach.
- Bez zakomentowanego martwego kodu, bez ścieżek absolutnych typu C:\Users\..., bez powtarzania tego samego bloku kodu wielokrotnie metodą kopiuj-wklej.
- Nazwy zmiennych i funkcji zrozumiałe bez dodatkowego komentarza. Komentarze wyjaśniające dlaczego, nie co.

6. Błędy dyskwalifikujące

Poniższe błędy unieważniają wynik pracy niezależnie od jej pozostałych zalet, ponieważ prowadzą do zawyżonej i nieprawdziwej oceny jakości modelu. Ich wystąpienie oznacza konieczność poprawy pracy przed dopuszczeniem do obrony. Lista jest jednocześnie listą kontrolną do samodzielnego sprawdzenia pracy przed oddaniem.

Błąd	Dlaczego jest dyskwalifikujący
Skalowanie lub imputacja przed podziałem danych	Parametry przekształcenia (średnia, odchylenie, mediana) wyliczone na całym zbiorze przenoszą informację ze zbioru testowego do treningowego. Wynik na zbiorze testowym przestaje być wiarygodny.
Selekcja cech na całym zbiorze	Ta sama pułapka w wersji groźniejszej: wybór cech na podstawie ich związku ze zmienną celu, dokonany przed podziałem, potrafi zawyżyć metrykę o kilkanaście punktów procentowych.
Ocena modelu na danych, na których był uczony	Nie mierzy zdolności generalizacji, a jedynie zdolność zapamiętania.
Losowy podział szeregu czasowego	Model uczy się na przyszłości i przewiduje przeszłość. W zadaniach prognostycznych podział musi być chronologiczny.
Losowy podział danych zawierających wiele obserwacji tego samego podmiotu	Obserwacje tej samej osoby, maszyny czy pacjenta trafiają jednocześnie do zbioru treningowego i testowego. Wymagany jest podział grupowy.
Wyciek zmiennej celu	Wśród cech znajduje się zmienna, która powstaje po zdarzeniu lub je zawiera. Katalog wskazuje takie zmienne w kilku tematach - zadaniem uczestnika jest je rozpoznać.
Trafność jako jedyna metryka przy niebalansowanych klasach	Przy klasie pozytywnej stanowiącej 1% obserwacji model odpowiadający zawsze „nie” osiąga 99% trafności i jest bezużyteczny.
Wielokrotne dobieranie modelu na zbiorze testowym	Zbiór testowy użyty do wyboru rozwiązania przestaje być zbiorem testowym. Do doboru służy zbiór walidacyjny lub walidacja krzyżowa.
Wnioski przyczynowe z danych obserwacyjnych	Sformułowanie „czynnik X powoduje Y” na podstawie korelacji lub istotności cechy w modelu jest nadinterpretacją.

7. Kryteria oceny pracy

Praca oceniana jest w skali 100 punktów według poniższej rubryki. Ocena pracy stanowi, wraz z oceną egzaminu końcowego, składnik ostatecznego wyniku studiów zgodnie z Załącznikiem 9 programu kształcenia.

Kryterium	Punkty	Co jest oceniane
Sformułowanie problemu i celu	10	Czy pytanie badawcze jest konkretne i sprawdzalne. Czy uzasadnienie wyboru tematu jest merytoryczne.
Praca ze zbiorem danych	20	Rzetelność eksploracyjnej analizy danych, jakość i udokumentowanie czyszczenia, świadomość ograniczeń zbioru, uzasadnienie decyzji dotyczących braków i wartości odstających.
Metodyka i poprawność walidacji	25	Poprawność strategii walidacji, brak wycieku informacji, uzasadnienie wyboru metod i metryk, obecność punktu odniesienia. Kryterium o największej wadze.
Wyniki i ich interpretacja	15	Czy wyniki odpowiadają na postawione pytanie, jakość wykresów, obecność analizy błędów, uczciwość wobec ograniczeń wyniku.
Jakość i reprodukowalność kodu	15	Struktura repozytorium, odtwarzalność wyników, czystość kodu, zgodność liczb w pracy z wynikami kodu.
Jakość redakcyjna i bibliografia	10	Kompletność struktury, poprawność językowa, jednolitość cytowań, poprawne opisanie tabel i rysunków.
Samodzielność i inicjatywa	5	Elementy wykraczające poza minimum tematu: dodatkowy eksperyment, własna weryfikacja, sięgnięcie do literatury pierwotnej.

Kryterium	Punkty	Co jest oceniane
Razem	100	

Przeliczenie punktów na ocenę: 90-100 - 5,0; 80-89 - 4,5; 70-79 - 4,0; 60-69 - 3,5; 50-59 - 3,0; poniżej 50 - ocena niedostateczna i konieczność poprawy pracy.

8. Obrona pracy i egzamin końcowy

Zgodnie z Załącznikiem 6 programu kształcenia egzamin końcowy składa się z dwóch części.

8.1. Prezentacja pracy końcowej (około 10 minut)

Sugerowany układ prezentacji, dopasowany do przewidzianego czasu:

- Problem i cel - 1 slajd, około 1,5 minuty.
- Dane: źródło, wielkość, największa napotkana trudność - 1-2 slajdy, około 2 minuty.
- Sposób rozwiązania: schemat procesu, nie lista bibliotek - 1-2 slajdy, około 2,5 minuty.
- Wyniki: jedna główna tabela lub wykres oraz porównanie z punktem odniesienia - 2 slajdy, około 3 minuty.
- Wnioski i ograniczenia - 1 slajd, około 1 minuta.

Zalecenie praktyczne: jeden slajd - jedna myśl. Prezentacja przeładowana treścią jest częstszym powodem obniżenia oceny niż słaby wynik modelu.

8.2. Egzamin ustny

Komisja zadaje trzy pytania dotyczące zarówno teorii, jak i praktyki omówionej w pracy. Przykładowe obszary pytań, na które warto się przygotować:

- Dlaczego wybrano tę metodę, a nie inną? Jakie są jej założenia i czy zostały spełnione?
- Dlaczego ta metryka jest właściwa dla tego zadania? Co by się zmieniło przy innej metryce?
- Gdzie w tym procesie mógłby wystąpić wyciek informacji i jak temu zapobiec?
- Co się stanie z tym modelem po roku działania w środowisku produkcyjnym?
- Czego na podstawie tych danych stwierdzić nie można i dlaczego?

Warunkiem dopuszczenia do egzaminu końcowego jest uzyskanie pozytywnych ocen ze wszystkich kursów objętych programem kształcenia.

9. Harmonogram

Terminy podano względem daty obrony (T). Dokładne daty kalendarzowe zostaną ogłoszone na początku drugiego semestru.

Etap	Termin	Zakres
1	T - 12 tygodni	Wybór tematu z katalogu i zgłoszenie go kierownikowi studiów (karta wyboru - Załącznik C). Zatwierdzenie tematu własnego, jeśli uczestnik proponuje własny.
2	T - 10 tygodni	Pozyskanie zbioru danych, założenie repozytorium, pierwszy commit z plikiem README i szkicem eksploracyjnej analizy danych. Potwierdzenie, że dane są dostępne i dają się wczytać.
3	T - 8 tygodni	Konsultacja pierwsza: przedstawienie eksploracyjnej analizy danych i planu metodycznego. To moment na wyłapanie błędnej strategii walidacji, zanim powstanie cała praca.
4	T - 5 tygodni	Konsultacja druga: pierwsze wyniki modelowania wraz z punktem odniesienia. Weryfikacja, czy nie doszło do wycieku informacji.

Etap	Termin	Zakres
5	T - 3 tygodnie	Oddanie pełnej wersji roboczej pracy oraz odnośnika do repozytorium do wglądu opiekuna.
6	T - 1 tydzień	Oddanie wersji ostatecznej pracy i prezentacji. Repozytorium zamknięte, bez dalszych zmian.
7	T	Egzamin końcowy: prezentacja pracy oraz egzamin ustny.

Dwie konsultacje są obowiązkowe. Doświadczenie pokazuje, że najczęstszą przyczyną słabych prac jest nie brak umiejętności, lecz błąd metodyczny popełniony na początku i powtarzany do końca.

10. Etyka, dane osobowe, licencje i narzędzia AI

10.1. Dane i licencje

- Każdy wykorzystany zbiór danych musi być w pracy zacytowany: nazwa, autor lub instytucja, adres źródła, data pobrania i licencja. Jeżeli zbiór ma publikację źródłową, cytuje się także publikację.
- Należy sprawdzić i respektować warunki licencji. Część zbiorów wskazanych w katalogu dopuszcza wyłącznie użytek niekomercyjny (Financial PhraseBank, MVTec AD), część wymaga akceptacji regulaminu (zbiory konkursowe serwisu Kaggle), część wymaga podania formuły atrybucyjnej (dane IMGW, GIOŚ).
- Dane udostępniane przez kierownika studiów podlegają odrębnym zasadom opisanym w Załączniku A i nie mogą być publikowane ani przekazywane osobom trzecim.
- W pracy i w repozytorium nie mogą znaleźć się dane umożliwiające identyfikację osób fizycznych, w tym dane na poziomie indywidualnego pacjenta.

10.2. Odpowiedzialność analityczna

- Pracę należy zakończyć uczciwą listą ograniczeń. Brak takiej listy jest brakiem merytorycznym, nie brakiem redakcyjnym.
- W tematach dotyczących ludzi - zdrowia, zatrudnienia, zdolności kredytowej - wymagane jest omówienie potencjalnych konsekwencji błędnych decyzji modelu i możliwej nierównomierności jego jakości między grupami osób.
- Nie wolno przedstawiać wyników na danych syntetycznych lub przykładowych jako wniosków o rzeczywistości. Katalog wskazuje, które zbiory są syntetyczne.

10.3. Korzystanie z narzędzi sztucznej inteligencji

Narzędzia oparte na dużych modelach językowych są elementem współczesnego warsztatu i ich użycie jest dozwolone na następujących zasadach:

- Dozwolone: pomoc w pisaniu i debugowaniu kodu, wyjaśnianie komunikatów o błędach, poprawa językowa własnego tekstu, wyszukiwanie literatury do samodzielnej weryfikacji.
- Niedozwolone: wygenerowanie tekstu pracy lub jej rozdziałów, wygenerowanie wyników, liczb lub wykresów bez uruchomienia własnego kodu, wygenerowanie bibliografii bez sprawdzenia istnienia każdej pozycji.
- Wymagane: krótkie oświadczenie na końcu pracy, w jakim zakresie wykorzystano narzędzia AI. Oświadczenie o użyciu takich narzędzi nie obniża oceny; ich nieujawnione użycie jest naruszeniem zasad.
- Uczestnik odpowiada za każdą liczbę i każde zdanie w pracy. Podczas egzaminu ustnego komisja może poprosić o wyjaśnienie dowolnego fragmentu kodu lub tekstu. Nieumiejętność wyjaśnienia własnej pracy jest oceniana jak brak jej wykonania.

Nie wolno wprowadzać do narzędzi zewnętrznych danych udostępnionych przez kierownika studiów ani danych objętych tajemnicą przedsiębiorstwa.

CZĘŚĆ II

Katalog tematów prac końcowych

Katalog obejmuje 40 tematów w pięciu obszarach zastosowań, o trzech poziomach zaawansowania. Dla każdego tematu wskazano konkretny, sprawdzony zbiór danych wraz z adresem źródła i informacją o licencji. Poziom tematu określa oczekiwany zakres pracy, nie maksymalną możliwą ocenę.

Obszar	Podstawowy	Średni	Zaawansowany	Razem	Numery tematów
Medycyna i zdrowie	3	4	2	9	1-9
Przemysł i produkcja	3	4	1	8	10-17
IoT i energetyka	3	3	2	8	18-25
Zarządzanie i biznes	3	3	1	7	26-32
Finanse	3	3	2	8	33-40
Razem	15	17	8	40	

11. Zestawienie tematów

Nr	Temat	Obszar	Poziom	Zbiór danych
1	Ocena ryzyka choroby niedokrwiennej serca na podstawie danych klinicznych	Medycyna	Podstawowy	UCI Heart Disease
2	Predykcja ryzyka udaru mózgu w zbiorze z brakami danych i niezbalansowaniem klas	Medycyna	Podstawowy	Kaggle Stroke Prediction
3	Klasyfikacja zmian nowotworowych piersi - porównanie klasyfikatorów na danych morfometrycznych	Medycyna	Podstawowy	UCI Breast Cancer Wisconsin
4	Predykcja ponownej hospitalizacji pacjentów z cukrzycą - pipeline na dużym zbiorze klinicznym	Medycyna	Średni	UCI Diabetes 130-US
5	Klasyfikacja stanu płodu na podstawie parametrów kardiokardiograficznych z analizą interpretowalności	Medycyna	Średni	UCI Cardiotocography
6	Architektura sieci powiązań biomarkerów endokrynno-metabolicznych w zespole policystycznych jajników	Medycyna	Średni	Kohorta PCOS (dane własne)
7	Białko Klotho jako biomarker - modelowanie zależności w kohorcie klinicznej	Medycyna	Średni	Kohorta Klotho (dane własne)
8	Wieloetykietowa klasyfikacja zapisów elektrokardiograficznych metodami uczenia głębokiego	Medycyna	Zaawansowany	PhysioNet PTB-XL
9	Fenotypowanie pacjentek z PCOS metodami klasteryzacji z oceną stabilności rozwiązania	Medycyna	Zaawansowany	Kohorta PCOS (dane własne)
10	Predykcyjne utrzymanie maszyn - klasyfikacja awarii na podstawie danych procesowych	Przemysł	Podstawowy	UCI AI4I 2020
11	Modelowanie wytrzymałości betonu na ściskanie na podstawie składu mieszanki	Przemysł	Podstawowy	UCI Concrete Strength

Nr	Temat	Obszar	Poziom	Zbiór danych
12	Klasyfikacja typów wad powierzchniowych blach stalowych	Przemysł	Podstawowy	UCI Steel Plates Faults
13	Selekcja cech w warunkach nadmiarowości sygnałów procesowych i rzadkości zdarzeń	Przemysł	Średni	UCI SECOM
14	Monitorowanie stanu układu hydraulicznego - inżynieria cech z sygnałów czujnikowych	Przemysł	Średni	UCI Hydraulic Systems
15	Modelowanie emisji tlenku węgla i tlenków azotu turbiny gazowej z analizą dryfu modelu	Przemysł	Średni	UCI Gas Turbine CO/NOx
16	Ocena jakości kłód sosny zwyczajnej na podstawie rozkładu wad - klasyfikacja z wyjaśnialnością	Przemysł	Średni	Wady kłód sosny (dane własne)
17	Wizualna kontrola jakości odlewów - klasyfikacja obrazów kontra detekcja anomalii	Przemysł	Zaawansowany	Kaggle Casting Product / MVTec AD
18	Detekcja obecności osób w pomieszczeniu na podstawie danych z czujników środowiskowych	IoT	Podstawowy	UCI Occupancy Detection
19	Predykcja zużycia energii przez urządzenia domowe na podstawie danych z sieci czujników	IoT	Podstawowy	UCI Appliances Energy
20	Jakość powietrza w wybranym mieście - budowa własnego zbioru danych z publicznego API	IoT	Podstawowy	API GIOŚ + IMGW
21	Prognozowanie dobowego profilu zużycia energii elektrycznej w gospodarstwie domowym	IoT	Średni	UCI Household Power
22	Rozpoznawanie aktywności człowieka na podstawie sygnałów z sensorów smartfona	IoT	Średni	UCI HAR Smartphones
23	Analiza pracy turbiny wiatrowej - krzywa mocy i wykrywanie odchyleń od charakterystyki	IoT	Średni	Kaggle Wind Turbine SCADA
24	Wykrywanie ataków botnetów w ruchu sieciowym urządzeń Internetu Rzeczy	IoT	Zaawansowany	UCI N-BaIoT
25	Prognozowanie generacji ze źródeł odnawialnych w Krajowym Systemie Elektroenergetycznym	IoT	Zaawansowany	API PSE + IMGW
26	Ocena skuteczności kampanii telemarketingowej banku	Zarządzanie	Podstawowy	UCI Bank Marketing
27	Analiza absencji pracowniczej - identyfikacja czynników i predykcja czasu nieobecności	Zarządzanie	Podstawowy	UCI Absenteeism at work
28	Predykcja odejść klientów operatora telekomunikacyjnego	Zarządzanie	Podstawowy	Kaggle Telco Churn
29	Segmentacja klientów i analiza koszykowa w sklepie internetowym	Zarządzanie	Średni	UCI Online Retail II
30	Analiza satysfakcji klientów i terminowości dostaw w marketplace - praca na wielotabelowym zbiorze	Zarządzanie	Średni	Kaggle Olist E-Commerce
31	Predykcja anulowania rezerwacji hotelowej i wybór progu decyzyjnego według kosztu biznesowego	Zarządzanie	Średni	Kaggle Hotel Booking Demand
32	Porównawcza analiza rozwoju jednostek terytorialnych na podstawie danych statystyki publicznej	Zarządzanie	Zaawansowany	API GUS BDL + Eurostat

Nr	Temat	Obszar	Poziom	Zbiór danych
33	Scoring kredytowy z uwzględnieniem asymetrycznej macierzy kosztów	Finanse	Podstawowy	UCI German Credit
34	Modelowanie wysokości kosztów ubezpieczenia zdrowotnego	Finanse	Podstawowy	Kaggle Medical Cost
35	Analiza zmienności kursów walut na podstawie danych Narodowego Banku Polskiego	Finanse	Podstawowy	API NBP
36	Ocena ryzyka niewypłacalności posiadaczy kart kredytowych z kalibracją prawdopodobieństw	Finanse	Średni	UCI Credit Card Default
37	Detekcja oszustw kartowych w warunkach skrajnego niezbalansowania klas	Finanse	Średni	Kaggle Credit Card Fraud
38	Analiza ryzyka portfela akcji notowanych na Giełdzie Papierów Wartościowych	Finanse	Średni	Stooq (GPW)
39	Analiza sentymentu w komunikatach finansowych metodami przetwarzania języka naturalnego	Finanse	Zaawansowany	HF Financial PhraseBank
40	Ocena zdolności kredytowej na podstawie wielu powiązanych źródeł danych - inżynieria cech na skalę	Finanse	Zaawansowany	Kaggle Home Credit

12. Medycyna i zdrowie

Obszar wymagający największej ostrożności interpretacyjnej. Modele dotyczą ludzi, więc obok metryki liczy się to, jakie konsekwencje ma błąd i czy wnioski nie wykraczają poza to, co dane pozwalają stwierdzić.

Temat 1. Ocena ryzyka choroby niedokrwiennej serca na podstawie danych klinicznych

Poziom: Podstawowy | **Obszar:** Medycyna

Zadanie główne: Zbudować i zinterpretować model regresji logistycznej przewidujący obecność istotnej choroby wieńcowej. Nacisk pracy leży na interpretacji współczynników (ilorazy szans) i konfrontacji ich z wiedzą kliniczną, a nie na maksymalizacji metryki.

Zbiór danych: Heart Disease (Cleveland), UCI ML Repository, ID 45 - 303 rekordy, 13 cech, licencja CC BY 4.0, pliki tekstowe.

<https://archive.ics.uci.edu/dataset/45/heart+disease>

Metody i narzędzia: Eksploracyjna analiza danych, obsługa braków, kodowanie zmiennych kategoriowych, regresja logistyczna, drzewo decyzyjne jako punkt odniesienia, ROC-AUC, macierz pomyłek, 5-krotna walidacja krzyżowa.

Oczekiwany rezultat: Raport z rankingiem czynników ryzyka wraz z ilorazami szans i przedziałami ufności; wskazanie, które zależności są zgodne z literaturą, a które mogą być artefaktem małej próby.

Uwagi: Mały zbiór - obowiązkowa dyskusja niepewności oszacowań. Temat bezpieczny na start.

Temat 2. Predykcja ryzyka udaru mózgu w zbiorze z brakami danych i niezbalansowaniem klas

Poziom: Podstawowy | **Obszar:** Medycyna

Zadanie główne: Przewidzieć wystąpienie udaru, ucząc się poprawnie postępować z brakami w zmiennej BMI oraz z klasą pozytywną stanowiącą kilka procent obserwacji.

Zbiór danych: Stroke Prediction Dataset (autor: fedesoriano), Kaggle - 11 cech klinicznych. Wymagane darmowe konto Kaggle; licencję należy sprawdzić na stronie zbioru.

<https://www.kaggle.com/datasets/fedesoriano/stroke-prediction-dataset>

Metody i narzędzia: Analiza wzorca braków, imputacja wykonywana wewnątrz pipeline'u, ważenie klas i techniki próbkowania, precyzja i czułość, krzywa precision-recall, świadomy wybór progu decyzyjnego.

Oczekiwany rezultat: Porównanie co najmniej trzech strategii radzenia sobie z niezbalansowaniem oraz rekomendacja progu decyzyjnego przy założonym koszcie przeoczenia pacjenta.

Uwagi: Kluczowy wniosek pracy: trafność (accuracy) na poziomie 95% jest w tym zadaniu bezwartościowa.

Temat 3. Klasyfikacja zmian nowotworowych piersi - porównanie klasyfikatorów na danych morfometrycznych

Poziom: Podstawowy | **Obszar:** Medycyna

Zadanie główne: Porównać co najmniej cztery klasyfikatory na zbiorze z 30 silnie skorelowanymi cechami oraz ocenić wpływ standaryzacji i redukcji wymiarowości na wynik.

Zbiór danych: Breast Cancer Wisconsin (Diagnostic), UCI ML Repository, ID 17 - 569 rekordów, 30 cech, licencja CC BY 4.0.

<https://archive.ics.uci.edu/dataset/17/breast+cancer+wisconsin+diagnostic>

Metody i narzędzia: Analiza korelacji, standaryzacja, analiza głównych składowych, k najbliższych sąsiadów, maszyna wektorów nośnych, las losowy, regresja logistyczna, krzywe ROC i PR, powtarzana walidacja krzyżowa, test istotności różnic między modelami.

Oczekiwany rezultat: Tabela porównawcza modeli z przedziałami ufności i uczciwym wnioskiem, czy zaobserwowane różnice między modelami są istotne statystycznie.

Uwagi: Zbiór dostępny również bezpośrednio w bibliotece scikit-learn - wygodny na pierwsze kroki.

Temat 4. Predykcja ponownej hospitalizacji pacjentów z cukrzycą - pipeline na dużym zbiorze klinicznym

Poziom: Średni | **Obszar:** Medycyna

Zadanie główne: Zbudować kompletny, reprodukowalny pipeline dla ponad 100 tysięcy rekordów z 47 cechami, w tym kodami diagnostycznymi ICD-9 i licznymi brakami, i przewidzieć readmisję pacjenta w ciągu 30 dni.

Zbiór danych: Diabetes 130-US hospitals for years 1999-2008, UCI ML Repository, ID 296 - 101 766 rekordów, 47 cech, licencja CC BY 4.0, pliki CSV.

<https://archive.ics.uci.edu/dataset/296/diabetes+130-us+hospitals+for+years+1999-2008>

Metody i narzędzia: Grupowanie kodów ICD-9 w kategorie kliniczne, kodowanie zmiennych o wysokiej liczności kategorii, ColumnTransformer i Pipeline w scikit-learn, gradient boosting, przeszukiwanie hiperparametrów, istotność permutacyjna cech, krzywa kalibracji.

Oczekiwany rezultat: Model z uzasadnionym progiem decyzyjnym, analiza jakości w podgrupach pacjentów oraz rozdział o realnej użyteczności klinicznej wyniku.

Uwagi: Uwaga na wyciek informacji: kolumny opisujące sposób wypisu pacjenta częściowo zawierają odpowiedź.

Temat 5. Klasyfikacja stanu płodu na podstawie parametrów kardiotokograficznych z analizą interpretowalności

Poziom: Średni | **Obszar:** Medycyna

Zadanie główne: Przeprowadzić trójklasową klasyfikację stanu płodu (prawidłowy, podejrzany, patologiczny) z naciskiem na wyjaśnienie decyzji modelu metodą SHAP i porównanie uzyskanych wag z parametrami stosowanymi w praktyce położniczej.

Zbiór danych: Cardiotocography, UCI ML Repository, ID 193 - 2 126 rekordów, 21 cech, licencja CC BY 4.0, format XLS (wymaga konwersji).

<https://archive.ics.uci.edu/dataset/193/cardiotocography>

Wygodniejszy wariant CSV: <https://www.kaggle.com/datasets/andrewmvd/fetal-health-classification>

Metody i narzędzia: Klasyfikacja wieloklasowa, wieloklasowa macierz pomyłek, metryki makro i mikro, gradient boosting, wartości SHAP, pogłębiona analiza błędów na klasie pośredniej.

Oczekiwany rezultat: Raport z profilami cech charakterystycznymi dla każdej klasy oraz wskazaniem, które błędy modelu byłyby klinicznie najbardziej kosztowne.

Uwagi: Dobry temat dla osoby, którą interesuje interpretowalność modeli.

Temat 6. Architektura sieci powiązań biomarkerów endokrynno-metabolicznych w zespole policystycznych jajników

Poziom: Średni | **Obszar:** Medycyna

Zadanie główne: Zbudować i opisać sieć powiązań korelacyjnych między biomarkerami w kohorcie pacjentek z PCOS oraz wskazać biomarkery pełniące rolę pomostów między obszarem hormonalnym i metabolicznym.

Zbiór danych: Kohorta PCOS - około 1 286 pacjentek, 29 biomarkerów endokrynnych, metabolicznych, tarczycowych i zapalnych. Zbiór udostępniany przez kierownika studiów na zasadach opisanych w Załączniku A.

Metody i narzędzia: Korelacje rangowe Spearmana, korekta dla wielokrotnego testowania metodą FDR, budowa grafu powiązań, miary centralności (stopień wierzchołka, pośrednictwo), wizualizacja sieci w bibliotece NetworkX, analiza wrażliwości wyników na przyjęty próg korelacji.

Oczekiwany rezultat: Mapa sieci biomarkerów z rankingiem wierzchołków pomostowych oraz ocena, jak silnie wnioski zależą od arbitralnie przyjętego progu.

Uwagi: Temat dla osoby zainteresowanej analizą grafową; nie wymaga uczenia maszynowego, wymaga natomiast rzetelności statystycznej.

Temat 7. Białko Klotho jako biomarker - modelowanie zależności w kohorcie klinicznej

Poziom: Średni | **Obszar:** Medycyna

Zadanie główne: Ocenic, w jakim stopniu stężenie białka Klotho daje się przewidzieć na podstawie pozostałych parametrów klinicznych oraz czy wnosi ono informację niezależną od klasycznych wskaźników metabolicznych.

Zbiór danych: Kohorta z oznaczeniami białka Klotho. Zbiór udostępniany przez kierownika studiów; szczegółowa specyfikacja zmiennych i liczebności w Załączniku A.

Metody i narzędzia: Regresja liniowa i regularyzowana (Ridge, Lasso), diagnostyka reszt, selekcja cech, ocena przyrostu wyjaśnianej wariancji w modelach zagnieżdżonych, walidacja krzyżowa, analiza wpływu wartości odstających.

Oczekiwany rezultat: Model regresyjny z omówieniem parametrów współtowarzyszących stężeniu Klotho oraz jasnym stwierdzeniem granic wnioskowania (współwystępowanie nie jest przyczynowością).

Uwagi: Temat o dużym potencjale rozwinięcia; wymaga dyscypliny w formułowaniu wniosków.

Temat 8. Wieloetykietowa klasyfikacja zapisów elektrokardiograficznych metodami uczenia głębokiego

Poziom: Zaawansowany | **Obszar:** Medycyna

Zadanie główne: Zaprojektować i wytrenować jednowymiarową sieć konwolucyjną klasyfikującą dwunastoodprowadzeniowe zapisy EKG według diagnostycznych nadkategorii, a następnie porównać ją z modelem klasycznym na cechach wyznaczonych ręcznie.

Zbiór danych: PTB-XL, wersja 1.0.3, PhysioNet - 21 799 zapisów od 18 869 pacjentów, po 10 s, częstotliwości 100 i 500 Hz, format WFDB, około 1,7 GB, dostęp otwarty bez rejestracji, licencja CC BY 4.0, gotowy podział na 10 foldów.

<https://physionet.org/content/ptb-xl/1.0.3/>

Metody i narzędzia: Wczytywanie sygnałów w formacie WFDB, filtracja i normalizacja, jednowymiarowa sieć konwolucyjna (PyTorch lub Keras), klasyfikacja wieloetykietowa, makro AUC, wykorzystanie oficjalnego podziału na foldy, augmentacja sygnału.

Oczekiwany rezultat: Model głęboki wraz z uczciwym porównaniem do prostszego punktu odniesienia oraz dyskusją kosztu obliczeniowego i czasu inferencji.

Uwagi: Duży wolumen danych; zalecane GPU lub cierpliwość. Temat dla osoby z zapleczem programistycznym.

Temat 9. Fenotypowanie pacjentek z PCOS metodami klasteryzacji z oceną stabilności rozwiązania

Poziom: Zaawansowany | **Obszar:** Medycyna

Zadanie główne: Wyodrębnić podgrupy (fenotypy) pacjentek metodami klasteryzacji i - co jest właściwym celem pracy - sprawdzić, czy uzyskany podział jest stabilny, czy jest artefaktem wyboru algorytmu i parametrów.

Zbiór danych: Kohorta PCOS - około 1 286 pacjentek, 29 biomarkerów. Zbiór udostępniany przez kierownika studiów, Załącznik A.

Metody i narzędzia: k-średnich, mieszaniny rozkładów Gaussa, klasteryzacja hierarchiczna, HDBSCAN; wybór liczby klastrow (indeks sylwetki, statystyka luki); resampling bootstrapowy i skorygowany indeks Randa jako miara stabilności; charakterystyka klastrow testami nieparametrycznymi z korektą FDR.

Oczekiwany rezultat: Wniosek o liczbie i stabilności fenotypów wraz z macierzą zgodności między algorytmami oraz jawnym stwierdzeniem, na ile podział jest odtwarzalny.

Uwagi: Temat najbliższy pracy badawczej, o wysokim potencjale rozwinięcia w publikację naukową.

13. Przemysł i produkcja

Obszar, w którym zdarzenia interesujące (awarie, braki) są rzadkie, a koszty błędów asymetryczne. Tematy uczą pracy z niezbalansowaniem, nadmiarowością sygnałów i dryfem procesu w czasie.

Temat 10. Predykcyjne utrzymanie maszyn - klasyfikacja awarii na podstawie danych procesowych

Poziom: Podstawowy | **Obszar:** Przemysł

Zadanie główne: Przewidzieć awarię maszyny na podstawie parametrów procesu oraz ustalić, które z pięciu trybów awarii model rozpoznaje, a których nie wykrywa wcale.

Zbiór danych: AI4I 2020 Predictive Maintenance Dataset, UCI ML Repository, ID 601 - 10 000 rekordów, 14 kolumn, 5 trybów awarii, bez braków danych, licencja CC BY 4.0, plik CSV.

<https://archive.ics.uci.edu/dataset/601/ai4i+2020+predictive+maintenance+dataset>

Metody i narzędzia: Eksploracyjna analiza danych, cechy pochodne (moc jako iloczyn momentu i prędkości, różnica temperatur), drzewo decyzyjne, las losowy, analiza jakości osobno dla każdego trybu awarii, macierz pomyłek.

Oczekiwany rezultat: Model wraz ze wskazaniem trzech najważniejszych sygnałów ostrzegawczych oraz dyskusją skutków fałszywego alarmu w służbach utrzymania ruchu.

Uwagi: Zbiór jest syntetyczny - należy to jasno zaznaczyć w rozdziale o ograniczeniach.

Temat 11. Modelowanie wytrzymałości betonu na ściskanie na podstawie składu mieszanki

Poziom: Podstawowy | **Obszar:** Przemysł

Zadanie główne: Przewidzieć wytrzymałość betonu na ściskanie w funkcji składu mieszanki i wieku próbki oraz zbadać nieliniowy charakter zależności od wieku.

Zbiór danych: Concrete Compressive Strength, UCI ML Repository, ID 165 - 1 030 rekordów, 8 cech wejściowych, licencja CC BY 4.0, plik XLS.

<https://archive.ics.uci.edu/dataset/165/concrete+compressive+strength>

Metody i narzędzia: Regresja liniowa, regresja z cechami wielomianowymi, drzewa regresyjne, las losowy, metryki RMSE, MAE i R kwadrat, diagnostyka reszt, wykresy zależności częściowej.

Oczekiwany rezultat: Porównanie modeli oraz interpretowalne wnioski technologiczne dotyczące wpływu stosunku wody do cementu, dodatków mineralnych i wieku próbki.

Uwagi: Bardzo czytelny zbiór regresyjny - dobry wybór na pierwszy samodzielny projekt.

Temat 12. Klasyfikacja typów wad powierzchniowych blach stalowych

Poziom: Podstawowy | **Obszar:** Przemysł

Zadanie główne: Rozpoznać siedem typów wad powierzchniowych na podstawie 27 cech geometrycznych i fotometrycznych oraz ocenić, które klasy są dla modelu najtrudniejsze i dlaczego.

Zbiór danych: Steel Plates Faults, UCI ML Repository, ID 198 - 1 941 rekordów, 27 cech, 7 klas, licencja CC BY 4.0.

<https://archive.ics.uci.edu/dataset/198/steel+plates+faults>

Metody i narzędzia: Klasyfikacja wieloklasowa, standaryzacja, k najbliższych sąsiadów, maszyna wektorów nośnych, las losowy, stratyfikowana walidacja krzyżowa, macierz pomyłek, metryki liczone osobno dla każdej klasy.

Oczekiwany rezultat: Raport z analizą klas trudnych i mało licznych oraz propozycją usprawnienia klasyfikatora dla klasy zbiorczej.

Uwagi: Dobre wprowadzenie do problemu klasyfikacji wieloklasowej z nierównymi licznosciami klas.

Temat 13. Selekcja cech w warunkach nadmiarowości sygnałów procesowych i rzadkości zdarzeń

Poziom: Średni | **Obszar:** Przemysł

Zadanie główne: Z 591 sygnałów czujnikowych wyłonić zestaw istotny dla wykrycia braku produkcyjnego, mając do dyspozycji zaledwie 104 przypadki wadliwe na 1 567 obserwacji.

Zbiór danych: SECOM (semiconductor manufacturing), UCI ML Repository, ID 179 - 1 567 rekordów, 591 cech, liczne braki danych, licencja CC BY 4.0.

<https://archive.ics.uci.edu/dataset/179/secom>

Metody i narzędzia: Usuwanie cech o zerowej wariancji i wysokiej wzajemnej korelacji, imputacja, testy jednoczynnikowe, rekurencyjna eliminacja cech, regularyzacja L1, PR-AUC jako metryka wiodąca, powtarzana stratyfikowana walidacja krzyżowa.

Oczekiwany rezultat: Porównanie trzech metod selekcji cech pod kątem stabilności wyboru między foldami - cecha wybrana raz nie jest odkryciem, a zbieżność metod jest.

Uwagi: Temat o klasycznej pułapce sytuacji, gdy liczba cech przewyższa liczbę obserwacji. Bardzo wysoka wartość dydaktyczna.

Temat 14. Monitorowanie stanu układu hydraulicznego - inżynieria cech z sygnałów czujnikowych

Poziom: Średni | **Obszar:** Przemysł

Zadanie główne: Z surowych szeregów czasowych siedemnastu czujników próbkowanych z częstotliwościami 100 Hz, 10 Hz i 1 Hz wyznaczyć cechy agregujące i przewidzieć stopień degradacji czterech komponentów układu.

Zbiór danych: Condition monitoring of hydraulic systems, UCI ML Repository, ID 447 - 2 205 cykli po 60 sekund, sygnały ciśnienia, przepływu, temperatury, wibracji i mocy, cztery zmienne wynikowe, licencja CC BY 4.0.

<https://archive.ics.uci.edu/dataset/447/condition+monitoring+of+hydraulic+systems>

Metody i narzędzia: Inżynieria cech z szeregów czasowych (statystyki opisowe, kwantyle, nachylenie trendu, energia sygnału, cechy widmowe z transformaty Fouriera), predykcja czterech zmiennych wynikowych, porównanie z podejściem na surowych próbkach.

Oczekiwany rezultat: Udokumentowany zestaw cech oraz wykazanie, o ile świadoma inżynieria cech przewyższa podanie modelowi wszystkich surowych próbek.

Uwagi: Rdzeniem pracy jest przetwarzanie sygnałów, nie wybór algorytmu.

Temat 15. Modelowanie emisji tlenu węgla i tlenków azotu turbiny gazowej z analizą dryfu modelu

Poziom: Średni | **Obszar:** Przemysł

Zadanie główne: Przewidzieć emisje na podstawie jedenastu pomiarów procesowych, a następnie sprawdzić, jak jakość modelu wytrenowanego na latach 2011-2012 pogarsza się na danych z lat 2014-2015.

Zbiór danych: Gas Turbine CO and NOx Emission Data Set, UCI ML Repository, ID 551 - 36 733 rekordy godzinowe z lat 2011-2015, pięć plików CSV, bez braków, licencja CC BY 4.0.

<https://archive.ics.uci.edu/dataset/551/gas+turbine+co+and+nox+emission+data+set>

Metody i narzędzia: Regresja wielowyjściowa, podział chronologiczny zbiorów (nie losowy), analiza dryfu koncepcji, retrenowanie krokowe, porównanie strategii aktualizacji modelu.

Oczekiwany rezultat: Wykres degradacji jakości modelu w czasie oraz uzasadniona rekomendacja częstotliwości retrenowania.

Uwagi: Naturalne wprowadzenie do zagadnień MLOps omawianych w module "Praktyczne aspekty pracy Data Scientist".

Temat 16. Ocena jakości kłód sosny zwyczajnej na podstawie rozkładu wad - klasyfikacja z wyjaśnialnością

Poziom: Średni | **Obszar:** Przemysł

Zadanie główne: Przewidzieć przemysłową klasę jakości kłody na podstawie rozkładu wad w segmentach podłużnych oraz wyjaśnić decyzje modelu w kategoriach zrozumiałych dla brakarza.

Zbiór danych: Dane o wadach kłód sosny zwyczajnej (*Pinus sylvestris*) - 684 kłody z pięciu nadleśnictw, wady opisane w dziewięciu segmentach podłużnych na odcinku 0-14 m, w formacie warstwowym. Zbiór udostępniany przez kierownika studiów, Załącznik A.

Metody i narzędzia: Przetworzenie danych z formatu warstwowego do tabeli cech, inżynieria cech przestrzennych (rozkład wad wzdłuż kłody), gradient boosting, wartości SHAP, analiza cech dominujących.

Oczekiwany rezultat: Model klasyfikacyjny wraz z interpretacją, które typy wad i w których segmentach kłody rzeczywiście decydują o klasie jakości.

Uwagi: Dane rzeczywiste i wymagające czyszczenia - istotną częścią pracy jest samo przygotowanie danych. Temat z realnym zastosowaniem przemysłowym.

Temat 17. Wizualna kontrola jakości odlewów - klasyfikacja obrazów kontra detekcja anomalii

Poziom: Zaawansowany | **Obszar:** Przemysł

Zadanie główne: Zbudować klasyfikator obrazów rozróżniający element wadliwy i poprawny, a następnie porównać go z podejściem opartym na detekcji anomalii, uczonym wyłącznie na próbkach poprawnych - i ocenić, które podejście lepiej pasuje do realiów kontroli jakości.

Zbiór danych: Casting Product Image Data for Quality Inspection, Kaggle - obrazy wirników pomp zatapialnych, dwie klasy, warianty 300x300 i 512x512.

<https://www.kaggle.com/datasets/ravirajsinh45/real-life-industrial-dataset-of-casting-product>

Alternatywnie MVTec AD - licencja CC BY-NC-SA 4.0, wyłącznie użytek niekomercyjny, wymagane cytowanie: <https://www.mvtec.com/research-teaching/datasets/mvtec-ad>

Metody i narzędzia: Sieć konwolucyjna z uczeniem transferowym (ResNet, EfficientNet), augmentacja obrazów, autoenkoder konwolucyjny jako detektor anomalii, mapy Grad-CAM, porównanie obu paradygmatów na tych samych danych testowych.

Oczekiwany rezultat: Dwa modele oraz uzasadniona rekomendacja, które podejście wybrać w sytuacji, gdy wad jest mało i są nieprzewidywalne.

Uwagi: Wymaga podstaw uczenia głębokiego; zalecane środowisko z GPU (Google Colab jest wystarczający).

14. Internet Rzeczy i energetyka

Obszar danych czujnikowych i szeregów czasowych. Wspólnym motywem jest poprawna walidacja czasowa, integracja źródeł i praca z danymi o dużej objętości.

Temat 18. Detekcja obecności osób w pomieszczeniu na podstawie danych z czujników środowiskowych

Poziom: Podstawowy | **Obszar:** IoT

Zadanie główne: Rozpoznać obecność ludzi w pomieszczeniu na podstawie temperatury, wilgotności, natężenia światła i stężenia dwutlenku węgla oraz ocenić, który czujnik jest najbardziej wartościowy i z których można zrezygnować.

Zbiór danych: Occupancy Detection, UCI ML Repository, ID 357 - 20 560 rekordów, 6 cech, próbkowanie co minutę, trzy pliki (zbiór treningowy i dwa testowe), licencja CC BY 4.0.

<https://archive.ics.uci.edu/dataset/357/occupancy+detection>

Metody i narzędzia: Eksploracyjna analiza szeregów, cechy kalendarzowe (godzina, dzień tygodnia), regresja logistyczna, drzewo decyzyjne, las losowy, ocena na dwóch niezależnych zbiorach testowych, analiza relacji kosztu czujnika do jakości modelu.

Oczekiwany rezultat: Rekomendacja minimalnego zestawu czujników dla systemu sterowania oświetleniem i wentylacją w budynku.

Uwagi: Zbiór ma gotowy podział na zbiory testowe - należy z niego skorzystać, a nie dzielić danych losowo.

Temat 19. Predykcja zużycia energii przez urządzenia domowe na podstawie danych z sieci czujników

Poziom: Podstawowy | **Obszar:** IoT

Zadanie główne: Przewidzieć zużycie energii w budynku niskoenergetycznym oraz sprawdzić, czy zastosowane metody oceny istotności cech poprawnie odrzucają dwie celowo wstawione do zbioru zmienne losowe.

Zbiór danych: Appliances Energy Prediction, UCI ML Repository, ID 374 - 19 735 rekordów, 28 cech, próbkowanie co 10 minut, około 4,5 miesiąca, licencja CC BY 4.0, plik CSV.

<https://archive.ics.uci.edu/dataset/374/appliances+energy+prediction>

Metody i narzędzia: Regresja, cechy kalendarzowe, las losowy, gradient boosting, istotność permutacyjna cech, diagnostyka reszt, porównanie z modelem naiwnym.

Oczekiwany rezultat: Model regresyjny oraz demonstracja, że poprawnie przeprowadzona ocena istotności cech odrzuca zmienne losowe - co jest testem rzetelności całego warsztatu.

Uwagi: Zbiór celowo zawiera dwie zmienne bez wartości informacyjnej. Ich wykrycie jest istotną częścią zadania.

Temat 20. Jakość powietrza w wybranym mieście - budowa własnego zbioru danych z publicznego API

Poziom: Podstawowy | **Obszar:** IoT

Zadanie główne: Pobrać dane z API Państwowego Monitoringu Środowiska, zbudować i udokumentować własny zbiór danych, opisać jego jakość (braki, awarie stacji) oraz przeanalizować sezonowość zanieczyszczeń.

Zbiór danych: API GIOŚ - dostęp bez klucza, format JSON, endpointy wersjonowane:

<https://api.gios.gov.pl/pjp-api/v1/rest/station/findAll> (lista stacji)

<https://api.gios.gov.pl/pjp-api/v1/rest/station/sensors/{stationId}> (stanowiska)

<https://api.gios.gov.pl/pjp-api/v1/rest/data/getData/{sensorId}> (pomiar)

Dokumentacja: <https://powietrze.gios.gov.pl/pjp/content/api>

Uzupełniając dane meteorologiczne IMGW: <https://danepubliczne.imgw.pl/api/data/synop>

Metody i narzędzia: Praca z interfejsem REST (biblioteka requests), parsowanie JSON, budowa i zapis własnego zbioru, obsługa limitów zapytań, analiza szeregów czasowych, dekompozycja sezonowa, wizualizacja.

Oczekiwany rezultat: Udokumentowany zbiór własny wraz z analizą dobowego i tygodniowego profilu stężeń PM10 i PM2,5, odniesioną do warunków meteorologicznych.

Uwagi: Starsze, niewersjonowane endpointy GIOŚ zostały wycofane - obowiązuje ścieżka z segmentem /v1/. Dla danych archiwalnych limit wynosi 2 zapytania na minutę i trzeba to obsłużyć w kodzie. Wymagana atrybucja źródła danych.

Temat 21. Prognozowanie dobowego profilu zużycia energii elektrycznej w gospodarstwie domowym

Poziom: Średni | **Obszar:** IoT

Zadanie główne: Zagregować dane minutowe z czterech lat do rozdzielczości godzinowej i zbudować prognozę zużycia energii na 24 godziny wprzód, uczciwie porównaną z modelem naiwnym sezonowym.

Zbiór danych: Individual Household Electric Power Consumption, UCI ML Repository, ID 235 - 2 075 259 rekordów, próbkowanie co minutę, XII 2006 - XI 2010, licencja CC BY 4.0, plik tekstowy około 127 MB.
<https://archive.ics.uci.edu/dataset/235/individual+household+electric+power+consumption>

Metody i narzędzia: Resampling i agregacja czasowa, uzupełnianie luk w szeregu, dekompozycja STL, model naiwny sezonowy jako punkt odniesienia, SARIMA lub Prophet, model regresyjny z cechami opóźnionymi, walidacja z kroczącym oknem czasowym (TimeSeriesSplit).

Oczekiwany rezultat: Prognoza z jawnym porównaniem do modelu naiwnego sezonowego. Model gorszy od punktu odniesienia jest wynikiem negatywnym, ale nadal jest wynikiem i podlega ocenie.

Uwagi: Bezwzględny zakaz losowego podziału na zbiór treningowy i testowy - podział musi być chronologiczny.

Temat 22. Rozpoznawanie aktywności człowieka na podstawie sygnałów z sensorów smartfona

Poziom: Średni | **Obszar:** IoT

Zadanie główne: Sklasyfikować sześć rodzajów aktywności na podstawie 561 cech wyznaczonych z akcelerometru i żyroskopu oraz zbadać, jak model radzi sobie z osobami, których nie widział w trakcie treningu.

Zbiór danych: Human Activity Recognition Using Smartphones, UCI ML Repository, ID 240 - 10 299 rekordów, 561 cech, 30 ochotników, 6 aktywności, licencja CC BY 4.0, archiwum około 58 MB.
<https://archive.ics.uci.edu/dataset/240/human+activity+recognition+using+smartphones>

Metody i narzędzia: Redukcja wymiarowości (analiza głównych składowych, t-SNE do wizualizacji), maszyna wektorów nośnych, las losowy, walidacja z podziałem po osobach (GroupKFold, leave-one-subject-out), analiza pomyłek między aktywnościami statycznymi.

Oczekiwany rezultat: Porównanie jakości modelu przy podziale losowym i przy podziale po osobach - z liczbową demonstracją, o ile podział losowy zawyża ocenę.

Uwagi: To temat o poprawnej strategii walidacji. Wniosek jest ważniejszy od samej metryki.

Temat 23. Analiza pracy turbiny wiatrowej - krzywa mocy i wykrywanie odchyłeń od charakterystyki

Poziom: Średni | **Obszar:** IoT

Zadanie główne: Odtworzyć rzeczywistą krzywą mocy turbiny wiatrowej, porównać ją z krzywą teoretyczną producenta i wskazać okresy nieprawidłowej pracy wraz z hipotezami przyczyn.

Zbiór danych: Wind Turbine Scada Dataset (autor: berkerisen), Kaggle - jedna turbina w Turcji, cały rok 2018, próbkowanie co 10 minut, kolumny: znacznik czasu, moc czynna, prędkość i kierunek wiatru, teoretyczna krzywa mocy.

<https://www.kaggle.com/datasets/berkerisen/wind-turbine-scada-dataset>

Metody i narzędzia: Eksploracyjna analiza szeregów, grupowanie po prędkości wiatru, regresja nieparametryczna (LOWESS, funkcje sklepane), analiza reszt względem krzywej teoretycznej, detekcja anomalii (Isolation Forest, progi na resztach), róża wiatrów.

Oczekiwany rezultat: Mapa okresów odbiegających od charakterystyki wraz z uzasadnionymi hipotezami przyczyn (postoje serwisowe, ograniczenie mocy, oblodzenie łopat).

Uwagi: Temat łączy analizę szeregów czasowych z detekcją anomalii i wymaga zdrowego rozsądku inżynierskiego.

Temat 24. Wykrywanie ataków botnetów w ruchu sieciowym urządzeń Internetu Rzeczy

Poziom: Zaawansowany | **Obszar:** IoT

Zadanie główne: Zbudować detektor ataków Mirai i BASHLITE na zbiorze ponad siedmiu milionów rekordów, a następnie sprawdzić zdolność detektora do wykrycia typu ataku i urządzenia nieobecnych w zbiorze treningowym.

Zbiór danych: detection_of_IoT_botnet_attacks_N_BaIoT, UCI ML Repository, ID 442 - 7 062 606 rekordów, 115 cech, 9 komercyjnych urządzeń IoT, dziesięć klas ataków oraz ruch prawidłowy, około 1,7 GB (część w archiwach RAR), licencja CC BY 4.0.

<https://archive.ics.uci.edu/dataset/442/detection+of+iot+botnet+attacks+n+baiot>

Metody i narzędzia: Praca z danymi przekraczającymi dostępną pamięć (wczytywanie porcjami, oszczędne typy danych, próbkowanie warstwowe), klasyfikacja wieloklasowa, detekcja nowości (One-Class SVM, autoenkoder) w scenariuszu nieznanego ataku, pomiar czasu inferencji.

Oczekiwany rezultat: Detektor wraz z eksperymentem generalizacji na nieznaną typ ataku oraz na nieznaną urządzenie - z uczciwym wnioskiem, na ile model jest przenośny.

Uwagi: Wymaga świadomego zarządzania pamięcią. Najbardziej "inżynierski" temat w katalogu.

Temat 25. Prognozowanie generacji ze źródeł odnawialnych w Krajowym Systemie Elektroenergetycznym

Poziom: Zaawansowany | **Obszar:** IoT

Zadanie główne: Połączyć dane o generacji wiatrowej i fotowoltaicznej z danymi meteorologicznymi z niezależnego źródła i zbudować prognozę krótkoterminową wraz z oceną niepewności.

Zbiór danych: API raportów PSE - dostęp bez klucza, JSON z filtrowaniem w składni OData:

<https://api.raporty.pse.pl/api/his-wlk-cal> (generacja, m.in. pola wiatrowe i fotowoltaiczne)

<https://api.raporty.pse.pl/api/rce-pln> (rynkowa cena energii, rozdzielczość 15 minut)

<https://api.raporty.pse.pl/api/obciazenie> lub [prog-obc](https://api.raporty.pse.pl/api/prog-obc) (zapotrzebowanie KSE)

API IMGW - dane synoptyczne bez klucza: <https://danepubliczne.imgw.pl/api/data/synop>

Archiwa meteorologiczne: https://danepubliczne.imgw.pl/data/dane_pomiarowo_obszerwacyjne/

Metody i narzędzia: Integracja wielu źródeł o różnej rozdzielczości czasowej, uzgodnienie znaczników czasu i stref czasowych, inżynieria cech meteorologicznych i kalendarzowych, gradient boosting, walidacja kroczącym oknem, prognoza kwantylowa (przedziały niepewności).

Oczekiwany rezultat: Prognoza z przedziałami niepewności oraz analiza, ile faktycznie wnoszą dane meteorologiczne w porównaniu z modelem opartym wyłącznie na historii generacji.

Uwagi: Wymagana atrybucja: "Źródłem pochodzenia danych jest Instytut Meteorologii i Gospodarki Wodnej - Państwowy Instytut Badawczy". Największy udział pracy stanowi integracja danych.

15. Zarządzanie i biznes

Obszar, w którym model jest tylko narzędziem decyzji. Każdy temat wymaga przełożenia wyniku na wartość biznesową i jawnego zapisania założeń kosztowych.

Temat 26. Ocena skuteczności kampanii telemarketingowej banku

Poziom: Podstawowy | **Obszar:** Zarządzanie

Zadanie główne: Przewidzieć, którzy klienci przyjmą ofertę lokaty terminowej, i przeliczyć wynik modelu na konkretną oszczędność kosztu kontaktów handlowych.

Zbiór danych: Bank Marketing, UCI ML Repository, ID 222 - 45 211 rekordów i 16 cech (wariant bank-additional-full.csv: 41 188 rekordów i 20 cech), dane rzeczywiste z portugalskiego banku 2008-2010, licencja CC BY 4.0, CSV z separatorem średnika.

<https://archive.ics.uci.edu/dataset/222/bank+marketing>

Metody i narzędzia: Eksploracyjna analiza danych, kodowanie zmiennych kategorycznych, regresja logistyczna, las losowy, krzywa lift i krzywa zysku kumulowanego, wybór progu decyzyjnego według kosztu jednego kontaktu.

Oczekiwany rezultat: Krzywa lift oraz wyliczenie, ile kontaktów można pominąć bez utraty istotnej części sprzedaży - czyli przełożenie modelu na decyzję operacyjną.

Uwagi: Zmienna "duration" (czas trwania rozmowy) jest jawnym wyciekiem informacji i musi zostać usunięta. Rozpoznanie tej pułapki jest głównym celem dydaktycznym tematu.

Temat 27. Analiza absencji pracowniczej - identyfikacja czynników i predykcja czasu nieobecności

Poziom: Podstawowy | **Obszar:** Zarządzanie

Zadanie główne: Zbadać, jakie czynniki współtowarzyszą dłuższej absencji w rzeczywistych danych firmy kurierskiej, zbudować model regresyjny i omówić granice dopuszczalnego użycia takiego modelu w decyzjach personalnych.

Zbiór danych: Absenteeism at work, UCI ML Repository, ID 445 - 740 rekordów, 19 cech, dane rzeczywiste z lat 2007-2010, licencja CC BY 4.0, formaty CSV, XLS i ARFF.

<https://archive.ics.uci.edu/dataset/445/absenteeism-at-work>

Metody i narzędzia: Eksploracyjna analiza danych, analiza sezonowości (miesiąc, dzień tygodnia), regresja liniowa, drzewa regresyjne, diagnostyka reszt, ocena istotności cech.

Oczekiwany rezultat: Raport z listą czynników współtowarzyszących absencji wraz z osobnym rozdziałem o etyce i granicach stosowania modeli predykcyjnych w obszarze HR.

Uwagi: Jeden z niewielu rzeczywistych, otwarcie licencjonowanych zbiorów HR. Rozdział etyczny jest tu obowiązkowy i podlega ocenie.

Temat 28. Predykcja odejść klientów operatora telekomunikacyjnego

Poziom: Podstawowy | **Obszar:** Zarządzanie

Zadanie główne: Zbudować model odejść klientów i przełożyć jego wynik na decyzję biznesową: kogo objąć akcją retencyjną przy zadanym, ograniczonym budżecie.

Zbiór danych: Telco Customer Churn (autor: blastchar), Kaggle - około 7 tysięcy klientów, 21 cech.

<https://www.kaggle.com/datasets/blastchar/telco-customer-churn>

Uwaga: to dane pokazowe pochodzenia IBM, nie dane rzeczywistego operatora - należy to jasno zaznaczyć w pracy.

Metody i narzędzia: Eksploracyjna analiza danych, obsługa kolumny TotalCharges z brakami zapisanymi jako spacja, kodowanie zmiennych, regresja logistyczna, gradient boosting, ranking klientów według ryzyka, analiza jakości w kolejnych decydach.

Oczekiwany rezultat: Lista priorytetowa klientów do objęcia retencją wraz z oszacowaniem zwrotu z akcji przy jawnie przyjętych założeniach kosztowych.

Uwagi: Bardzo dobry temat na start dla osoby z tłem biznesowym; zbiór jest czysty, więc ciężar pracy przenosi się na interpretację.

Temat 29. Segmentacja klientów i analiza koszykowa w sklepie internetowym

Poziom: Średni | **Obszar:** Zarządzanie

Zadanie główne: Przeprowadzić segmentację klientów metodą RFM, wyznaczyć reguły asocjacyjne między produktami i połączyć oba wyniki w spójną rekomendację marketingową.

Zbiór danych: Online Retail II, UCI ML Repository, ID 502 - 1 067 371 transakcji, 8 zmiennych, XII 2009 - XII 2011, dane rzeczywiste brytyjskiego sklepu internetowego, licencja CC BY 4.0, plik XLSX około 43 MB (dwa arkusze).

<https://archive.ics.uci.edu/dataset/502/online+retail+ii>

Metody i narzędzia: Czyszczenie danych (zwroty, ilości ujemne, braki identyfikatora klienta), obliczenie wskaźników RFM, k-średnich z uzasadnieniem liczby klastrów, algorytm Apriori lub FP-Growth (biblioteka mlxtend), miary wsparcia, ufności i przyrostu, walidacja segmentów na drugim roku danych.

Oczekiwany rezultat: Profile segmentów klientów oraz zestaw reguł produktowych wraz z oceną ich stabilności między dwoma latami - reguła obecna tylko w jednym roku nie jest rekomendacją.

Uwagi: Zbiór obejmujący dwa lata pozwala na rzetelną walidację czasową. To istotna przewaga nad popularnym zbiorem jednorocznym.

Temat 30. Analiza satysfakcji klientów i terminowości dostaw w marketplace - praca na wielotabelowym zbiorze

Poziom: Średni | **Obszar:** Zarządzanie

Zadanie główne: Połączyć dziewięć powiązanych tabel, zbadać, jak opóźnienie dostawy przekłada się na ocenę zamówienia, i zbudować model wczesnego ostrzegania o ryzyku niskiej oceny.

Zbiór danych: Brazilian E-Commerce Public Dataset by Olist, Kaggle - około 100 tysięcy zamówień z lat 2016-2018, dziewięć plików CSV (zamówienia, pozycje, płatności, opinie, klienci, produkty, sprzedawcy, geolokalizacja, tłumaczenia kategorii), dane rzeczywiste.

<https://www.kaggle.com/datasets/olistbr/brazilian-ecommerce>

Metody i narzędzia: Modelowanie relacyjne i łączenie tabel (pandas oraz równoważne zapytania SQL - bezpośrednie wykorzystanie modułu "Bazy danych i SQL"), cechy wyznaczane z różnic dat, analiza geograficzna, klasyfikacja niskiej oceny, analiza jakości w przekroju sprzedawców.

Oczekiwany rezultat: Wnioski operacyjne (o ile punktów obniża ocenę każdy dzień opóźnienia) oraz model wczesnego ostrzegania z uzasadnionym prognozą.

Uwagi: Najlepszy temat dla osoby, której najbardziej odpowiadał moduł baz danych - integruje SQL z analizą i modelowaniem.

Temat 31. Predykcja anulowania rezerwacji hotelowej i wybór progu decyzyjnego według kosztu biznesowego

Poziom: Średni | **Obszar:** Zarządzanie

Zadanie główne: Zbudować model anulacji rezerwacji i wyznaczyć próg decyzyjny minimalizujący koszt, przy jawnie założonej asymetrii kosztów pustego pokoju i nadmiernej rezerwacji.

Zbiór danych: Hotel Booking Demand, Kaggle - 119 390 rezerwacji (hotel wypoczynkowy: 40 060, miejski: 79 330), 31-32 zmienne, przyjazdy VII 2015 - VIII 2017, dane rzeczywiste dwóch portugalskich hoteli, zanonimizowane.

<https://www.kaggle.com/datasets/jessemostipak/hotel-booking-demand>

Publikacja źródłowa: Antonio N., de Almeida A., Nunes L., "Hotel booking demand datasets", Data in Brief 22 (2019) 41-49, DOI: 10.1016/j.dib.2018.11.126

Metody i narzędzia: Czystczenie danych (braki w kolumnach children, agent, company, rezerwacje o zerowej liczbie gości), cechy czasowe, gradient boosting, kalibracja prawdopodobieństw, macierz kosztów, optymalizacja progu decyzyjnego, walidacja chronologiczna.

Oczekiwany rezultat: Krzywa kosztu całkowitego w funkcji progu decyzyjnego wraz z rekomendowanym progiem i jawnie zapisanymi założeniami kosztowymi.

Uwagi: Kolumna reservation_status jest wyciekiem informacji i musi zostać usunięta. Zbiór ma recenzowaną publikację źródłową, którą należy cytować.

Temat 32. Porównawcza analiza rozwoju jednostek terytorialnych na podstawie danych statystyki publicznej

Poziom: Zaawansowany | **Obszar:** Zarządzanie

Zadanie główne: Zbudować wielowymiarowy profil powiatów lub regionów na podstawie danych z dwóch niezależnych API statystycznych, pogrupować jednostki i sprawdzić, czy uzyskana typologia jest trwała w czasie.

Zbiór danych: API Banku Danych Lokalnych GUS - <https://bdl.stat.gov.pl/api/v1/> (klucz opcjonalny, przekazywany w nagłówku X-ClientId; limity anonimowe 5 zapytań na sekundę; formaty JSON, XML, JSONAPI; dane na licencji CC BY 4.0; dokumentacja: <https://api.stat.gov.pl/Home/BdlApi>).
API Eurostat - <https://ec.europa.eu/eurostat/api/dissemination/statistics/> (bez klucza i rejestracji, format JSON-stat 2.0; przewodnik: <https://ec.europa.eu/eurostat/web/user-guides/data-browser/api-data-access/api-introduction>).
Uzupełniając portal Otwartych Danych: <https://dane.gov.pl/>

Metody i narzędzia: Automatyzacja pobierania danych z dwóch API o odmiennych schematach, harmonizacja kodów terytorialnych (TERYT, NUTS), standaryzacja wskaźników, analiza głównych składowych, klasteryzacja hierarchiczna i k-średnich, analiza zmian przynależności do klastrów w czasie, kartogram (biblioteka GeoPandas).

Oczekiwany rezultat: Typologia jednostek terytorialnych przedstawiona na mapie wraz z oceną, czy podział jest trwały, czy zmienia się rok do roku.

Uwagi: Zadanie w większości inżynieryjne - pozyskanie i uzgodnienie danych stanowi tu główną trudność, modelowanie jest krokiem końcowym.

16. Finanse

Obszar o najsilniejszej presji na rzetelność: liczy się nie tylko rankingowanie, ale też kalibracja prawdopodobieństw i uczciwa ocena poza próbą uczącą.

Temat 33. Scoring kredytowy z uwzględnieniem asymetrycznej macierzy kosztów

Poziom: Podstawowy | **Obszar:** Finanse

Zadanie główne: Zbudować model oceny wiarygodności kredytowej i wybrać próg decyzyjny zgodnie z oficjalną macierzą kosztów dołączoną do zbioru, w której błąd zaakceptowania złego kredytu jest pięciokrotnie droższy od odrzucenia dobrego.

Zbiór danych: Statlog (German Credit Data), UCI ML Repository, ID 144 - 1 000 rekordów, 20 cech, macierz kosztów w dokumentacji zbioru, licencja CC BY 4.0.

<https://archive.ics.uci.edu/dataset/144/statlog+german+credit+data>

Metody i narzędzia: Kodowanie zmiennych jakościowych, regresja logistyczna, drzewo decyzyjne, las losowy, koszt oczekiwany zamiast trafności jako kryterium wyboru, krzywa kosztu w funkcji progów, walidacja krzyżowa.

Oczekiwany rezultat: Model z progiem decyzyjnym wybranym na podstawie kosztu, a nie domyślnej wartości 0,5, wraz z pokazaniem, jak istotnie zmienia to podejmowane decyzje.

Uwagi: Najprostszy sposób zrozumienia, dlaczego domyślny próg 0,5 jest w zastosowaniach finansowych arbitralny i zwykle błędny.

Temat 34. Modelowanie wysokości kosztów ubezpieczenia zdrowotnego

Poziom: Podstawowy | **Obszar:** Finanse

Zadanie główne: Przewidzieć wysokość kosztu ubezpieczenia i zbadać interakcję między paleniem tytoniu a wskaźnikiem masy ciała, pokazując, że dobrze wybrana interakcja bywa cenniejsza od bardziej złożonego modelu.

Zbiór danych: Medical Cost Personal Datasets (plik insurance.csv), Kaggle - 1 338 rekordów, 7 kolumn. Dane przykładowe, nie rzeczywiste - należy to zaznaczyć w pracy.

<https://www.kaggle.com/datasets/mirichoi0218/insurance>

Metody i narzędzia: Eksploracyjna analiza danych, regresja liniowa, jawne wprowadzenie członu interakcyjnego, transformacja logarytmiczna zmiennej celu, diagnostyka reszt, drzewa regresyjne, metryki R kwadrat, RMSE i MAE.

Oczekiwany rezultat: Model regresyjny z demonstracją, że prosty model z uzasadnioną interakcją przewyższa model złożony bez niej.

Uwagi: Temat idealny na pierwszy projekt: mały zbiór, czytelna struktura, bardzo wyraźny efekt.

Temat 35. Analiza zmienności kursów walut na podstawie danych Narodowego Banku Polskiego

Poziom: Podstawowy | **Obszar:** Finanse

Zadanie główne: Pobrać historyczne kursy walut z publicznego API NBP, obliczyć stopy zwrotu i zmienność oraz porównać zachowanie wybranych par walutowych w odniesieniu do decyzji Rady Polityki Pieniężnej.

Zbiór danych: NBP Web API - dostęp bez klucza, formaty JSON i XML, wyłącznie protokół HTTPS (od 1 sierpnia 2025), pojedyncze zapytanie nie może obejmować okresu dłuższego niż 93 dni:

https://api.nbp.pl/api/exchangerates/rates/a/{kod}/{data_od}/{data_do}/

<https://api.nbp.pl/api/exchangerates/tables/a/>

Dokumentacja: <https://api.nbp.pl/>

Stopy procentowe NBP (odrębne źródło, XML z pełną historią):

https://static.nbp.pl/dane/stopy/stopy_procentowe_archiwum.xml

Metody i narzędzia: Praca z API i obsługa limitu 93 dni (pętla po kolejnych okresach), analiza szeregów czasowych, logarytmiczne stopy zwrotu, zmienność krocząca, korelacja par walutowych, test stacjonarności ADF, wizualizacja.

Oczekiwany rezultat: Raport o zmienności wybranych walut wraz z odniesieniem do decyzji o stopach procentowych w analizowanym okresie.

Uwagi: Wartość dydaktyczna tematu leży w pozyskaniu i uporządkowaniu danych, nie w złożoności modelu. Bardzo dobry temat na start.

Temat 36. Ocena ryzyka niewypłacalności posiadaczy kart kredytowych z kalibracją prawdopodobieństw

Poziom: Średni | **Obszar:** Finanse

Zadanie główne: Zbudować model niewypłacalności i wykazać, że wysokie AUC nie oznacza dobrze skalibrowanych prawdopodobieństw - a w zastosowaniach finansowych potrzebne jest jedno i drugie.

Zbiór danych: Default of Credit Card Clients, UCI ML Repository, ID 350 - 30 000 rekordów, 23 cechy, klienci tajwańscy z 2005 roku, licencja CC BY 4.0, format XLS z dwupoziomym nagłówkiem.
<https://archive.ics.uci.edu/dataset/350/default+of+credit+card+clients>

Metody i narzędzia: Przygotowanie danych z pliku XLS, cechy z sześciomiesięcznej historii płatności, regresja logistyczna, las losowy, gradient boosting, krzywa kalibracji, wskaźnik Briera, kalibracja Platt'a i izotoniczna, porównanie ROC-AUC z PR-AUC.

Oczekiwany rezultat: Porównanie modeli przed i po kalibracji wraz z wnioskiem, który z nich faktycznie nadaje się do wyceny ryzyka, a nie tylko do rankingowania klientów.

Uwagi: Temat wprowadza pojęcie, którego brakuje w większości kursów wprowadzających: kalibrację prawdopodobieństw.

Temat 37. Detekcja oszustw kartowych w warunkach skrajnego niezbalansowania klas

Poziom: Średni | **Obszar:** Finanse

Zadanie główne: Zbudować detektor oszustw w sytuacji, gdy klasa pozytywna stanowi około 0,17% obserwacji, i uczciwie ocenić jego użyteczność operacyjną, a nie tylko wartość metryki.

Zbiór danych: Credit Card Fraud Detection (Machine Learning Group, Université Libre de Bruxelles), Kaggle - transakcje europejskich kart z września 2013, około 284,8 tysiąca transakcji, 492 oszustwa (0,172%), 28 anonimowych cech po transformacji PCA oraz kolumny Time, Amount i Class; licencja Open Data Commons DbCL.
<https://www.kaggle.com/datasets/mlg-ulb/creditcardfraud>

Metody i narzędzia: PR-AUC i średnia precyzja jako metryki wiodące, porównanie strategii (ważenie klas, SMOTE, undersampling, detekcja anomalii bez etykiet), podział z zachowaniem porządku czasowego wynikającego z kolumny Time, analiza precyzji w pierwszych k alertach.

Oczekiwany rezultat: Rekomendacja jednej strategii wraz z uzasadnieniem operacyjnym (ile alertów dziennie jest w stanie obsłużyć zespół) oraz pokazanie, dlaczego SMOTE nie zawsze pomaga.

Uwagi: Cechy są anonimowe po transformacji PCA - to świadome ćwiczenie z modelowania bez możliwości interpretacji domenowej.

Temat 38. Analiza ryzyka portfela akcji notowanych na Gieldzie Papierów Wartościowych

Poziom: Średni | **Obszar:** Finanse

Zadanie główne: Zbudować portfel z kilku spółek notowanych na GPW, oszacować jego ryzyko i porównać wybrane strategie alokacji poza próbą uczącą.

Zbiór danych: Stooq - darmowy eksport CSV bez klucza, wzorec adresu: <https://stooq.pl/q/d/l/?s={ticker}&i=d> (parametr i przyjmuje wartości d, w, m; opcjonalnie &d1=RRRRMMDD&d2=RRRRMMDD; przykładowe tickery: wig20, pkn, kgh, pko). Dostęp również przez pandas_datareader ze źródłem "stooq". Uzupełniając stopy procentowe NBP: https://static.nbp.pl/dane/stopy/stopy_procentowe_archiwum.xml

Metody i narzędzia: Pobranie danych i uzgodnienie kalendarzy notowań, logarytmiczne stopy zwrotu, macierz kowariancji, zmienność, wartość zagrożona (podejście historyczne i parametryczne), maksymalne obsunięcie kapitału, porównanie portfela równych wag z portfelem minimalnej wariancji, ocena poza próbą.

Oczekiwany rezultat: Raport ryzyka portfela wraz z uczciwym wnioskiem, czy optymalizacja przewyższyła portfel równych wag poza próbą uczącą (zwykle nie przewyższa - i to jest wartościowe odkrycie).

Uwagi: Stooq nie udostępnia oficjalnego API ani jawnej licencji, a obowiązuje w nim nieoficjalny dzienny limit pobrań. Dane należy pobierać oszczędnie i zapisywać lokalnie. Wyłącznie użytek dydaktyczny.

Temat 39. Analiza sentymentu w komunikatach finansowych metodami przetwarzania języka naturalnego

Poziom: Zaawansowany | **Obszar:** Finanse

Zadanie główne: Zbudować klasyfikator sentymentu zdań finansowych i porównać trzy generacje podejść: reprezentację worka słów, osadzenia zdań oraz dostrojony model transformerowy.

Zbiór danych: Financial PhraseBank (Malo i in., 2014), Hugging Face - cztery konfiguracje według progu zgodności anotatorów: sentences_50agree (4 846 zdań), 66agree (4 217), 75agree (3 453), allagree (2 264); trzy klasy sentymentu; licencja CC BY-NC-SA 3.0, wyłącznie użytek niekomercyjny.
https://huggingface.co/datasets/takala/financial_phrasebank

Metody i narzędzia: Przetwarzanie wstępne tekstu, TF-IDF z regresją logistyczną, osadzenia zdań, dostrojenie modelu typu BERT lub FinBERT (biblioteka transformers), porównanie jakości na czterech progach zgodności anotatorów, analiza błędów, ocena kosztu obliczeniowego.

Oczekiwany rezultat: Porównanie trzech podejść wraz z wnioskiem, jak jakość etykiet - mierzona zgodnością anotatorów - ogranicza osiągalną jakość modelu.

Uwagi: Licencja niekomercyjna; obowiązkowe cytowanie: Malo P., Sinha A., Korhonen P., Wallenius J., Takala P., "Good Debt or Bad Debt: Detecting Semantic Orientations in Economic Texts", JASIST 65 (2014).

Temat 40. Ocena zdolności kredytowej na podstawie wielu powiązanych źródeł danych - inżynieria cech na skalę

Poziom: Zaawansowany | **Obszar:** Finanse

Zadanie główne: Zbudować model ryzyka kredytowego na siedmiu powiązanych tabelach i wykazać, że o jakości wyniku decyduje agregacja cech, a nie wybór algorytmu.

Zbiór danych: Home Credit Default Risk, Kaggle - siedem plików: application_train/test, bureau, bureau_balance, previous_application, POS_CASH_balance, credit_card_balance, installments_payments; klucze SK_ID_CURR, SK_ID_PREV, SK_ID_BUREAU; łącznie około 2,7 GB. Wymagane konto Kaggle i akceptacja regulaminu konkursu.
<https://www.kaggle.com/competitions/home-credit-default-risk>

Metody i narzędzia: Agregacje grupowe na tabelach podrzędnych (statystyki, liczniki, cechy z okien czasowych), zarządzanie pamięcią i typami danych, LightGBM lub XGBoost, stratyfikowana walidacja krzyżowa, selekcja cech, wartości SHAP, porównanie modelu na cechach z samego wniosku z modelem na pełnym zestawie cech.

Oczekiwany rezultat: Liczbowe pokazanie przyrostu jakości wynikającego wyłącznie z inżynierii cech oraz w pełni udokumentowany, reprodukowalny pipeline.

Uwagi: Temat najbliższy realnemu zadaniu Data Scientist w instytucji finansowej. Wymaga dyscypliny w organizacji kodu - bez niej praca staje się niereprodukowalna.

Załącznik A. Zbiory danych udostępniane przez kierownika studiów

Trzy tematy w katalogu (nr 6, 7, 9 oraz nr 16) opierają się na zbiorach pochodzących z prac badawczych prowadzonych na Wydziale. Zbiory te nie są publicznie dostępne i są udostępniane uczestnikom studiów wyłącznie na potrzeby pracy końcowej.

Zbiór	Charakterystyka i zastosowanie
Kohorta PCOS (tematy 6 i 9)	Około 1 286 pacjentek, 29 biomarkerów obejmujących obszar endokrynnny, metaboliczny, tarczycowy i zapalny. Dane w postaci tabeli zanonimizowanej. Zastosowanie: analiza sieciowa powiązań między biomarkerami oraz klasteryzacja z oceną stabilności rozwiązania.
Kohorta z oznaczeniami białka Klotho (temat 7)	Kohorta kliniczna z oznaczeniami stężenia białka Klotho oraz towarzyszącymi parametrami klinicznymi. Dokładna liczba obserwacji i pełna lista zmiennych przekazywane wraz ze zbiorem. Zastosowanie: modelowanie regresyjne i ocena przyrostu informacji wnoszonej przez biomarker.
Wady kłód sosny zwyczajnej (temat 16)	684 kłody sosny (<i>Pinus sylvestris</i>) z pięciu nadleśnictw. Wady opisane w dziewięciu segmentach podłużnych na odcinku 0-14 m, w formacie warstwowym (jedno drzewo zajmuje od jednego do pięciu wierszy, każdy wiersz to warstwa defektów; kody defektów w formacie liczba-typ-klasa wielkości). Zastosowanie: klasyfikacja przemysłowej klasy jakości drewna z analizą wyjaśnialności. Istotną częścią pracy jest przetworzenie danych do formatu analitycznego.

Warunki korzystania

1. Zbiór jest udostępniany po zgłoszeniu wyboru tematu i podpisaniu zobowiązania do zachowania poufności.
2. Dane mogą być wykorzystane wyłącznie do realizacji pracy końcowej na tych studiach.
3. Zabronione jest publikowanie zbioru, umieszczanie go w repozytorium publicznym, przekazywanie osobom trzecim oraz wprowadzanie go do zewnętrznych narzędzi i usług, w tym narzędzi opartych na dużych modelach językowych.
4. Repozytorium z kodem musi być prywatne, z dostępem nadanym opiekunowi pracy. Katalog z danymi objęty plikiem .gitignore.
5. W pracy i w plikach wynikowych nie mogą pojawić się wyniki na poziomie pojedynczej obserwacji - dopuszczalne są wyłącznie wyniki zagregowane.
6. Wykorzystanie zbioru wymaga umieszczenia w pracy formuły podziękowania oraz informacji o źródle danych, w brzmieniu przekazanym wraz ze zbiorem.
7. Jeżeli wyniki pracy miałyby zostać wykorzystane w publikacji naukowej, wymagane jest odrębne uzgodnienie z kierownikiem studiów przed jej złożeniem.

Załącznik B. Wzorcowa struktura repozytorium

Poniższą strukturę należy traktować jako punkt wyjścia. Nazwy katalogów są obowiązkowe, zawartość dostosowuje się do tematu.

```
praca-koncowa-<nazwisko>/
README.md           - opis, źródło danych, licencja, instrukcja odtworzenia
requirements.txt     - zależności z przypiętymi wersjami
.gitignore           - obowiązkowo wyklucza katalog data/
config.yaml          - parametry i ziarno generatora losowego (seed)
data/
  raw/               - dane źródłowe (nie commitowane)
  processed/         - dane po przetworzeniu (nie commitowane)
  README.md          - skąd i jak pobrać dane
notebooks/
  00_pozyskanie_danych.ipynb
  01_ed.ipynb
  02_przygotowanie_danych.ipynb
  03_modelowanie.ipynb
  04_wyniki_i_wykresy.ipynb
src/
  data_loader.py      - wczytywanie i walidacja danych
  features.py         - inżynieria cech
  models.py           - definicje modeli i pipeline
  evaluation.py        - metryki i wykresy
outputs/
  figures/            - wykresy użyte w pracy
  tables/             - tabele wynikowe
  models/             - zapisane modele
praca/
  praca_koncowa.docx
  prezentacja.pptx
```

Lista kontrolna przed oddaniem pracy

- Uruchomiłam/uruchomiłem notebooki od zera na czystym środowisku i wszystkie liczby w pracy się odtworzyły.
- Podział danych nastąpił przed jakimkolwiek skalowaniem, imputacją i selekcją cech.
- Sprawdziłam/sprawdziłem, czy wśród cech nie ma zmiennej powstającej po zdarzeniu, które przewiduję.
- W pracy jest punkt odniesienia (model naiwny) i porównanie z nim.
- Wybrane metryki są uzasadnione, a nie przyjęte domyślnie.
- Zbiór danych jest zacytowany wraz z licencją i datą pobrania.
- Repozytorium nie zawiera danych osobowych - także w historii commitów i w wynikach komórek notebooków.
- Praca ma rozdział o ograniczeniach, a wnioski nie są sformułowane przyczynowo bez podstaw.
- Dołączyłam/dołączyłem oświadczenie o zakresie wykorzystania narzędzi AI.

Załącznik C. Karta wyboru tematu pracy końcowej

Kartę należy wypełnić i przekazać kierownikowi studiów w terminie wskazanym w harmonogramie (etap 1).

Imię i nazwisko	
Numer wybranego tematu	
Tytuł tematu	
Poziom tematu	podstawowy / średni / zaawansowany
Zbiór danych	
Czy zbiór jest już pobrany i wczytany?	tak / nie
Krótkie uzasadnienie wyboru (2-3 zdania)	
Środowisko pracy (lokalne / Google Colab / inne)	
Temat własny - jeśli tak, opis problemu, źródło danych i podstawa prawna ich wykorzystania	
Data i podpis uczestnika	
Decyzja kierownika studiów	